Étude du risque de crédit et de l'inclusion financière

Data Science pour la banque et la FinTech

CHENGHO FONGANG Marie Louise

Octobre 2026

Sommaire

Abréviations 1

1. Résumé 2

2. Problématique et questions 3

3. Données 3
- 3.1 Source . . . 3
- 3.2 Un problème important : la table des codes d'origine est fausse . . . 3
- 3.3 Limites des données . . . 3

4. Méthode : les cinq étapes 4

5. Résultats 5
- 5.1 Qui fait défaut ? (SQL, étape 1) . . . 5
- 5.2 Tests statistiques et régression logistique (Q1) . . . 5
- 5.3 Performance du modèle et déséquilibre des classes (Q2) . . . 6
- 5.4 Seuil de décision et arbitrage financier (Q3) . . . 8
- 5.5 Segmentation du risque . . . 8
- 5.6 Expliquer le modèle avec SHAP . . . 9
- 5.7 Audit d'équité (Q4) . . . 11

6. Discussion : comment évaluer plus équitablement les clients mal desservis ? 11

7. Limites 12

8. Conclusion 12

Références 12

Abréviations

Abréviation	Signification
AUC	*Area Under the Curve* : aire sous la courbe ROC
CSV	*Comma-Separated Values* : fichier tableau simple
DI	*Disparate Impact* : taux d'acceptation d'un groupe divisé par celui d'un autre groupe
DM	Deutsche Mark (monnaie allemande avant l'euro)

Abréviation	Signification
EO	*Equal Opportunity* (égalité des chances) : les bons payeurs doivent avoir la même chance d'être acceptés dans chaque groupe
FN	Faux négatif : client accepté qui fait défaut
FP	Faux positif : bon client refusé
IA	Intelligence artificielle
IC	Intervalle de confiance (ici toujours à 95 %)
OR	*Odds Ratio* (rapport des cotes)
PD	Probabilité de défaut
ROC	*Receiver Operating Characteristic* : courbe des vrais positifs contre les faux positifs
SHAP	*SHapley Additive exPlanations* : méthode pour expliquer chaque prédiction
SQL	*Structured Query Language* : langage pour interroger une base de données
UCI	Université de Californie à Irvine (héberge le *Machine Learning Repository*)
UE	Union européenne
VC	Validation croisée

1. Résumé

Ce projet étudie 1 000 anciens crédits à la consommation d'une banque allemande. Il pose deux questions : quelles caractéristiques des clients sont associées au défaut de paiement, et comment un prêteur peut-il évaluer de manière plus équitable les clients mal desservis ?

Thème	Résultat principal
Données	1 000 crédits, 30 % de mauvais crédits. La table des codes d'origine était fausse pour 8 variables ; nous utilisons la table corrigée de Grömping (2019).
Facteurs les plus forts	Compte courant, historique de crédit, durée du prêt et épargne.
Modèle	Régression logistique sans sexe, âge ni statut de travailleur étranger. ROC-AUC sur le test = 0,80.
Règle de décision	Seuil P(défaut) = 1/6, issu de la matrice des coûts 5 :1. Économie de 22 % par rapport à la meilleure règle simple (« tout refuser »).
Accès au crédit	À ce seuil, seulement 40 % des demandeurs et 51 % des bons clients sont acceptés.
Classes de risque	Le taux de défaut va de 6,5 % (20 % les plus sûrs) à 62,5 % (20 % les plus risqués).
Équité	Les clients de 25 ans ou moins sont beaucoup moins acceptés, alors que le modèle n'utilise pas l'âge (DI = 0,65).

Message principal. Un modèle simple et transparent sépare bien le risque. Mais le seuil de décision est un choix économique et social, pas seulement technique. L'équité doit être mesurée, pas supposée. Ces résultats sont des corrélations historiques des années 1970. Ils ne prouvent pas qu'une personne est solvable ou non.

2. Problématique et questions

Une banque doit estimer le risque qu'un emprunteur ne rembourse pas. Si elle prête à trop de clients risqués, elle perd de l'argent. Si elle est trop stricte, de bons clients perdent l'accès au crédit. C'est un vrai problème d'inclusion financière : en 2021, environ 1,4 milliard d'adultes dans le monde n'avaient toujours pas de compte bancaire (Demirgüç-Kunt et al., 2022), et les personnes avec un historique financier court ou atypique sont souvent refusées. Dans l'Union européenne, les systèmes de notation de crédit sont désormais classés comme systèmes d'IA « à haut risque » (Union européenne, 2024) : ils doivent être transparents et contrôlés contre la discrimination.

Nous répondons à quatre questions :

- **Q1.** Quelles caractéristiques des clients sont associées au défaut ?
- **Q2.** Un modèle simple et interprétable peut-il séparer bons et mauvais clients ?
- **Q3.** Quelle règle de décision coûte le moins, et que signifie-t-elle pour l'accès au crédit ?
- **Q4.** Le modèle traite-t-il certains groupes moins bien, même sans utiliser de données sensibles ?

3. Données

3.1 Source

Nous utilisons le jeu de données public **Statlog (German Credit Data)** du UCI Machine Learning Repository (Hofmann, 1994). Il contient 1 000 crédits, 20 caractéristiques du client et du prêt, et une cible : bon crédit (remboursé comme prévu) ou mauvais crédit (non remboursé comme prévu). 30 % des crédits sont mauvais. Le jeu de données est fourni avec une **matrice des coûts** : accepter un client qui fait ensuite défaut coûte 5, refuser un bon client coûte 1.

3.2 Un problème important : la table des codes d'origine est fausse

Le fichier brut utilise des codes comme `A11` ou `A34`. La table des codes livrée avec les données explique ces codes. Grömping (2019) est revenue aux sources allemandes d'origine et a montré que cette table est **fausse pour 8 des 20 variables**. Voici les corrections les plus importantes :

Variable	Libellé d'origine (faux)	Libellé correct
checking_status A11	solde < 0 DM	pas de compte courant
checking_status A14	pas de compte courant	solde >= 200 DM ou compte salaire
credit_history A30	aucun crédit pris	retards de paiement dans le passé
credit_history A34	compte critique	tous les crédits dans cette banque remboursés
foreign_worker A201	oui (963 clients)	non (seulement 37 travailleurs étrangers)
personal_status_sex A92	femme	femme non célibataire **ou** homme célibataire

Nous avons découvert ce problème parce que nos premiers résultats n'avaient pas de sens : « pas de compte courant » et « compte critique » semblaient être les clients *les plus sûrs*. Après correction, les résultats deviennent logiques (section 5.1). **Leçon :** toujours vérifier que les résultats ont du sens, et vérifier la documentation des données.

Grömping (2019) donne deux autres informations importantes pour cette étude :

1. Les crédits datent de **1973 à 1975** et viennent d'une grande banque du sud de l'Allemagne.
2. Les mauvais crédits ont été **volontairement sur-représentés**. En réalité, seulement environ **5 %** des crédits étaient mauvais, et non 30 %. La banque a choisi 300 mauvais et 700 bons crédits pour avoir assez de cas de défaut.

3.3 Limites des données

- **Biais de sélection.** Nous ne voyons que les clients qui *ont obtenu* un crédit. Les personnes refusées sont absentes, donc nous ne savons pas si elles auraient remboursé (Thomas et al., 2017 ; Banasik & Crook, 2007).

— **Données anciennes et petites.** 1 000 crédits des années 1970. Les résultats montrent une méthode, pas la réalité d'aujourd'hui.
— **Le sexe n'est pas utilisable.** Le code A92 mélange femmes et hommes célibataires, donc le sexe ne peut pas être retrouvé. Nous n'auditons donc pas le sexe.
— **Très peu de travailleurs étrangers.** Seulement 37 personnes : tout résultat sur ce groupe est incertain.

4. Méthode : les cinq étapes

Toutes les étapes sont des scripts Python dans `src/`. La commande `python src/run_all.py` exécute tout et enregistre les tableaux et les graphiques dans `results/`. La graine aléatoire est fixée (42), donc les résultats sont toujours les mêmes.

Étape 1 : préparation des données et SQL (`01_data_prep.py`). Nous chargeons le fichier brut et appliquons la table des codes corrigée. Nous stockons les données dans une base SQLite et calculons en SQL les taux de défaut par segment (compte courant, historique, objet du crédit, tranche d'âge).

Étape 2 : analyse statistique (`02_statistics.py`, question Q1).

— Pour chaque variable qualitative : un **test du khi-deux** d'indépendance et le **V de Cramér** pour mesurer la force du lien, de 0 (aucun lien) à 1 (lien parfait) (Agresti, 2013).
— Pour chaque variable numérique : un **test de Mann-Whitney U** (Mann & Whitney, 1947), qui ne suppose pas une loi normale, et la **corrélation bisériale de rang** comme taille d'effet (Kerby, 2014).
— Nous faisons 20 tests, donc certains pourraient être significatifs par hasard. Nous utilisons la **correction de Bonferroni** : chaque p-valeur est multipliée par le nombre de tests (Bland & Altman, 1995).
— Ensuite, une **régression logistique multivariée** montre l'effet de chaque facteur « toutes choses égales par ailleurs ». Nous donnons les **odds ratios** (OR) avec un IC à 95 % : OR > 1 signifie plus de risque, OR < 1 moins de risque (Hosmer et al., 2013). Les variables numériques sont standardisées : leur OR correspond à +1 écart-type.

Étape 3 : modèle, seuil et segmentation du risque (`03_model.py`, questions Q2 et Q3).

— *Découpage.* 75 % des données pour l'apprentissage (750 crédits), 25 % pour le test final (250 crédits). Le jeu de test n'est utilisé qu'une seule fois, à la fin.
— *Modèle.* Une régression logistique. C'est le modèle de référence en notation de crédit (Siddiqi, 2017 ; Hand & Henley, 1997) et il reste difficile à battre (Lessmann et al., 2015). Il est aussi facile à expliquer, ce qui compte pour des décisions importantes (Rudin, 2019). Nous n'utilisons **pas** le sexe (personal_status_sex), l'âge ni le statut de travailleur étranger.
— *Déséquilibre des classes.* Il y a moins de mauvais crédits (30 %) que de bons (70 %). Une solution courante est de donner plus de poids à la petite classe (`class_weight="balanced"`) (He & Garcia, 2009). Nous comparons cette option avec un modèle normal, par validation croisée à 5 blocs sur le jeu d'apprentissage.
— *Seuil de décision.* Nous refusons un client si P(défaut) ≥ seuil. Avec les coûts 5 (FN) et 1 (FP), la théorie de la décision donne le seuil 1 / (1 + 5) = **0,167** (Elkan, 2001). Cette formule n'est valable que si les probabilités prédites sont réalistes (bien calibrées).
— *Comparaison.* Nous comparons le modèle à deux règles simples : tout accepter et tout refuser.
— *Classes de risque.* Chacun des 1 000 clients reçoit un score de validation croisée (calculé par un modèle qui n'a pas vu ce client) et nous les répartissons en 5 classes de même taille. Pour chaque classe, nous calculons le taux de défaut avec un intervalle de confiance de Wilson à 95 % (Wilson, 1927).

Étape 4 : expliquer le modèle avec SHAP (`04_shap.py`). Les valeurs SHAP montrent combien chaque variable augmente ou diminue une prédiction (Lundberg & Lee, 2017). Pour une régression logistique, la valeur SHAP est simplement *coefficient × (valeur du client − valeur moyenne)* (Molnar, 2022). Notre script vérifie cette formule : la différence est nulle.

Étape 5 : audit d'équité (`05_fairness.py`, question Q4). Nous utilisons les scores de validation croisée des 1 000 clients et le seuil 0,167. Groupes : âge ≤ 25 ans contre > 25 ans (le découpage utilisé par Kamiran & Calders, 2009, sur ces données) et travailleurs étrangers contre les autres. Nous calculons :

— **Impact disparate (DI)** : taux d'acceptation du groupe ÷ taux d'acceptation du groupe de référence. La « règle des 80 % » (*four-fifths rule*) signale un problème si DI < 0,8 (EEOC, 1978 ; Feldman et al., 2015).
— **Écart d'égalité des chances (EO)** : différence de taux d'acceptation *parmi les bons payeurs seulement*. Les personnes qui rembourseraient doivent avoir la même chance dans chaque groupe (Hardt et al., 2016).

— **IC bootstrap à 95 %** : nous ré-échantillonnons les clients 2 000 fois pour voir si chaque chiffre est stable (Efron & Tibshirani, 1993).
— **Modèle « aveugle » contre modèle « complet »** : un modèle sans données sensibles contre un modèle avec l'âge et le statut de travailleur étranger, pour voir si retirer ces variables supprime les écarts.

5. Résultats

5.1 Qui fait défaut ? (SQL, étape 1)

Compte courant	Clients	Taux de défaut
pas de compte courant	274	**49,3 %**
solde < 0 DM	269	39,0 %
0 à 200 DM	63	22,2 %
>= 200 DM ou compte salaire	394	**11,7 %**

Historique de crédit	Clients	Taux de défaut
retards de paiement dans le passé	40	**62,5 %**
compte critique / crédits ailleurs	49	57,1 %
aucun crédit / tous remboursés	530	31,9 %
crédits en cours remboursés normalement	88	31,8 %
tous les crédits dans cette banque remboursés	293	**17,1 %**

Avec les libellés corrigés, les résultats sont logiques : les clients sans compte courant ou avec des retards passés font le plus souvent défaut. Les clients avec un bon solde ou un bon historique dans la banque font le moins souvent défaut. Les crédits en défaut sont aussi plus gros (3 938 contre 2 985 DM en moyenne) et plus longs (24,9 contre 19,2 mois). Les jeunes (19 à 25 ans) font plus souvent défaut (42,1 %) que les 36 à 50 ans (23,7 %).

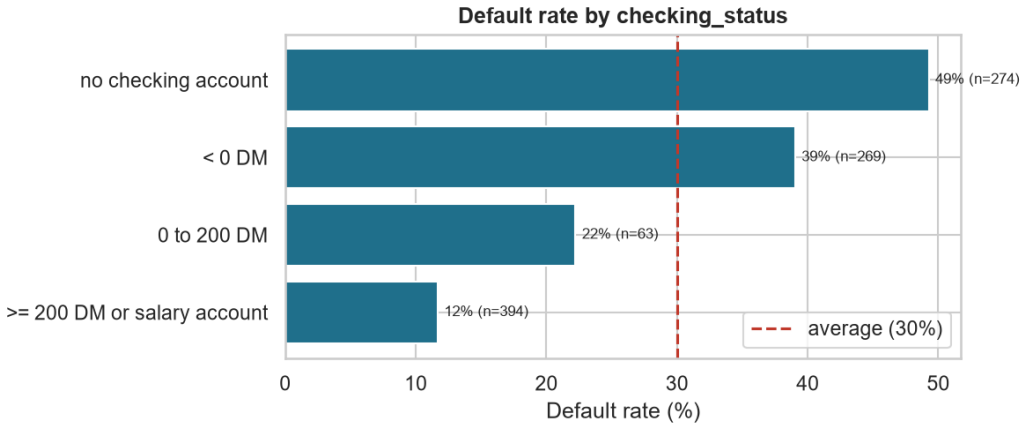


FIGURE 1 – Taux de défaut selon le compte courant

5.2 Tests statistiques et régression logistique (Q1)

Après correction de Bonferroni, 10 des 20 variables sont liées de façon significative au défaut. Les plus fortes sont :

Variable	Taille d'effet	p-valeur Bonferroni
checking_status	V de Cramér = 0,35	< 0,001

Variable	Taille d'effet	p-valeur Bonferroni
duration_months	r bisérial = 0,26	< 0,001
credit_history	V de Cramér = 0,25	< 0,001
savings	V de Cramér = 0,19	< 0,001
purpose	V de Cramér = 0,18	0,002
property	V de Cramér = 0,15	< 0,001
age	r bisérial = −0,14	0,008

Tous les effets sont faibles à moyens. Aucune variable ne prédit le défaut à elle seule.

La régression logistique (référence = catégorie la plus fréquente) donne ces principaux odds ratios :

Terme	OR	IC à 95 %	Effet
checking_status = pas de compte courant	5,41	3,45 à 8,47	plus de risque
checking_status = < 0 DM	3,98	2,54 à 6,26	plus de risque
purpose = autres	2,21	1,38 à 3,56	plus de risque
duration_months (+1 écart-type)	1,46	1,17 à 1,81	plus de risque
credit_amount (+1 écart-type)	1,35	1,06 à 1,73	plus de risque
savings = >= 1000 DM	0,38	0,23 à 0,62	moins de risque
credit_history = tous les crédits dans cette banque remboursés	0,40	0,24 à 0,65	moins de risque
other_debtors = garant	0,34	0,15 à 0,76	moins de risque
installment_rate = >= 35 % du revenu	0,44	0,25 à 0,77	moins de risque

La référence pour checking_status est « >= 200 DM » : un client sans compte courant a donc une cote de défaut environ 5 fois plus élevée qu'un client avec un bon solde, toutes choses égales par ailleurs.

Un résultat surprenant. Les clients qui remboursent une *grande* part de leur revenu (≥ 35 %) font *moins* souvent défaut. C'est probablement un effet de **sélection** : la banque n'acceptait des remboursements aussi lourds que pour des clients en qui elle avait confiance pour d'autres raisons. Cela montre pourquoi il faut parler d'**associations, pas de causes**.

Réponse à Q1. Le compte courant, l'historique de crédit, la durée et le montant du prêt et l'épargne sont les facteurs les plus fortement associés au défaut dans cet échantillon.

5.3 Performance du modèle et déséquilibre des classes (Q2)

Modèle (VC à 5 blocs, apprentissage)	ROC-AUC	PD moyenne prédite	Taux de défaut réel	Score de Brier
normal	0,759	0,300	0,300	0,176
équilibré (*balanced*)	0,758	0,435	0,300	0,200

Les deux modèles classent les clients de la même façon (même ROC-AUC). Mais le modèle « équilibré » prédit une probabilité moyenne de défaut de 43,5 % alors que le taux réel est de 30 % : ses probabilités sont trop élevées. Son score de Brier (une mesure de l'erreur sur les probabilités ; Brier, 1950) est aussi moins bon. C'est un effet connu de la repondération (Elkan, 2001 ; Niculescu-Mizil & Caruana, 2005). Comme la formule du seuil a besoin de probabilités réalistes, **nous gardons le modèle normal** et nous traitons le déséquilibre avec le seuil.

Sur le jeu de test, le modèle final atteint une **ROC-AUC de 0,80**. Une AUC de 0,5 correspond au hasard et 1,0 à un classement parfait (Fawcett, 2006) : le modèle est utile mais loin d'être parfait.

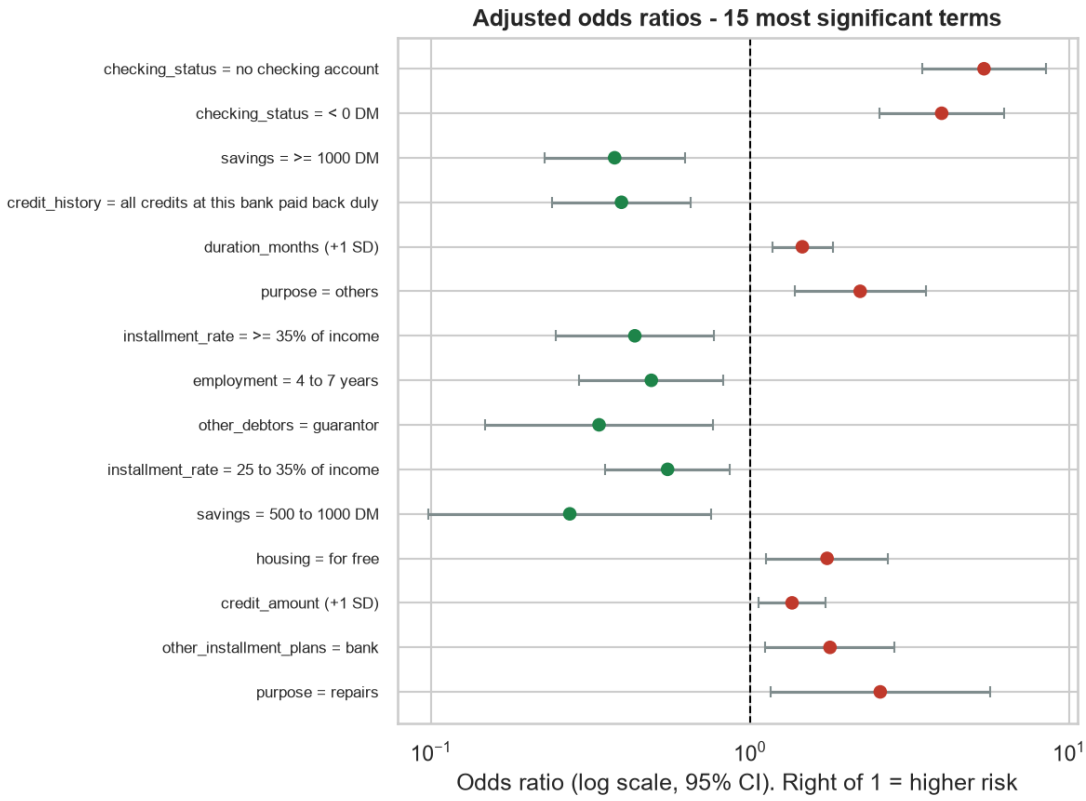


FIGURE 2 – Odds ratios ajustés

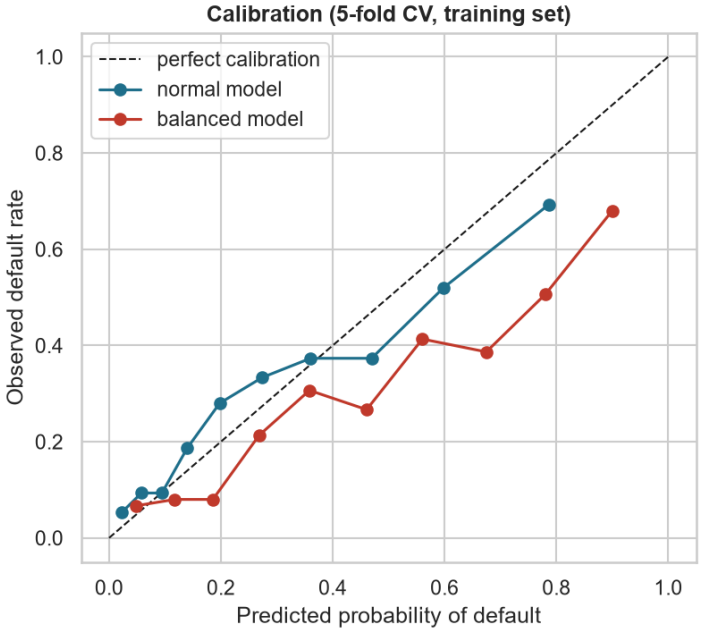


FIGURE 3 – Calibrage des deux modèles

5.4 Seuil de décision et arbitrage financier (Q3)

Sur le jeu d'apprentissage, le seuil le moins coûteux est 0,16, très proche de la théorie (0,167). Résultats sur le jeu de test (250 clients) :

Règle	Taux d'acceptation	Bons clients acceptés	Défaillants acceptés	Coût par client	Économie vs meilleure règle simple
Tout accepter	100 %	100 %	100 %	1,500	—
Tout refuser	0 %	0 %	0 %	0,700	référence
Modèle, seuil 0,50	73,6 %	86,3 %	44,0 %	0,756	−8 %
Modèle, seuil 0,167	**39,6 %**	**50,9 %**	**13,3 %**	**0,544**	**+22 %**

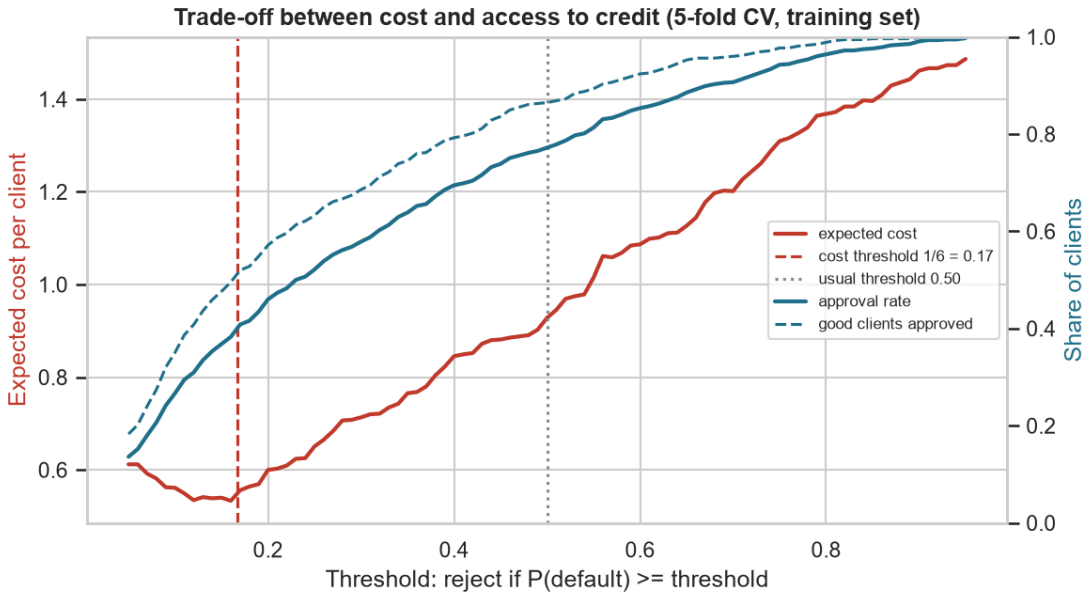


FIGURE 4 – Coût et taux d'acceptation selon le seuil

Ce que cela signifie.

1. Le seuil habituel de 0,50 est un mauvais choix ici. Il coûte *plus* que de tout refuser, car il accepte 44 % des défaillants.
2. Le seuil basé sur les coûts (0,167) est la meilleure règle, mais l'économie par rapport à « tout refuser » est de 22 %, pas plus. (La comparaison avec « tout accepter » donnerait 64 %, mais cette comparaison est trop facile.)
3. Le prix à payer est l'accès au crédit : **la moitié des bons clients est refusée**. C'est le cœur de l'arbitrage entre risque financier et inclusion financière.
4. Le ratio 5 :1 et le taux de défaut de 30 % poussent vers le refus. En réalité, seulement environ 5 % des crédits étaient mauvais (Grömping, 2019). Si l'on corrige les probabilités pour un taux de défaut de 5 % (correction des probabilités *a priori* ; Saerens et al., 2002 ; King & Zeng, 2001), le même seuil accepte **87 %** des demandeurs au lieu de 40 %. Un prêteur doit donc utiliser *son propre* taux de défaut et *ses propres* coûts. Une approche plus complète utiliserait les vrais gains et pertes (Verbraken et al., 2014).

5.5 Segmentation du risque

Classe	Clients	Taux de défaut	IC à 95 %	Action proposée
A (risque le plus faible)	200	6,5 %	3,8 % à 10,8 %	accepter, conditions standard
B	200	14,0 %	9,9 % à 19,5 %	accepter, conditions standard
C	200	27,0 %	21,3 % à 33,5 %	accepter avec un montant plus faible ou une durée plus courte
D	200	40,0 %	33,5 % à 46,9 %	analyse manuelle (garant, garantie)
E (risque le plus élevé)	200	62,5 %	55,6 % à 68,9 %	refuser, ou prêt garanti uniquement

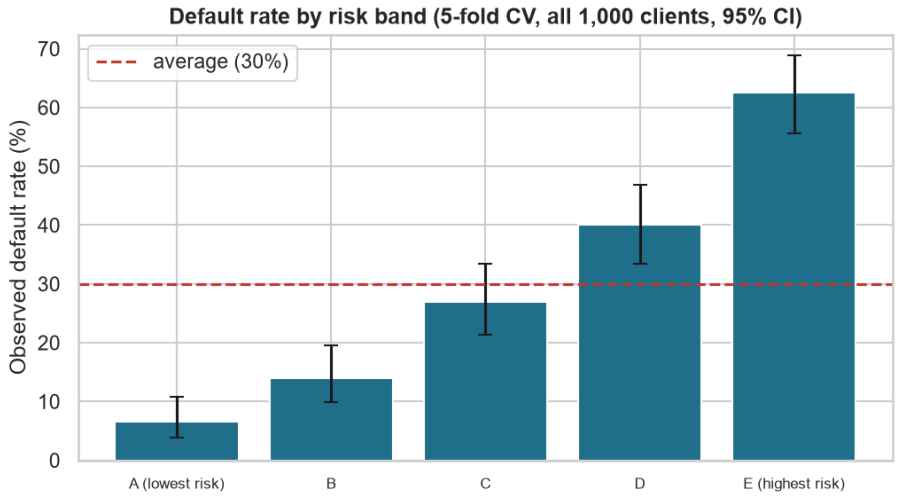


FIGURE 5 – Taux de défaut par classe de risque

Le taux de défaut augmente à chaque classe, et les intervalles de confiance de A et E sont très éloignés. Au lieu d'un simple oui/non, la banque peut **adapter les conditions du prêt** à la classe de risque (montant, durée, garant), comme c'est l'usage avec les grilles de score (Siddiqi, 2017). Cette approche « adapter plutôt que refuser » aide l'inclusion : un client des classes C ou D peut quand même obtenir un prêt, avec des conditions plus sûres. (Ces actions sont des exemples, pas des politiques testées.)

5.6 Expliquer le modèle avec SHAP

Les variables les plus importantes (valeur SHAP absolue moyenne, jeu de test) sont :

1. checking_status = « >= 200 DM ou compte salaire » (diminue le risque)
2. credit_history = « tous les crédits dans cette banque remboursés » (diminue le risque)
3. savings = « inconnue / pas de compte d'épargne » (augmente le risque)
4. duration_months (les prêts longs augmentent le risque)
5. checking_status = « pas de compte courant » (augmente le risque)

Les graphiques en cascade (*waterfall*) expliquent une décision pour un client. Par exemple, pour le client le plus risqué du jeu de test, la longue durée du prêt et l'objet « réparations » ajoutent le plus de risque. C'est le type d'explication qu'une banque devrait pouvoir donner à un client refusé.

Pour un modèle linéaire, SHAP n'apporte pas d'information nouvelle par rapport aux coefficients. Son intérêt est de présenter l'information **client par client**, de façon claire. Certains effets semblent étranges (par exemple, être propriétaire

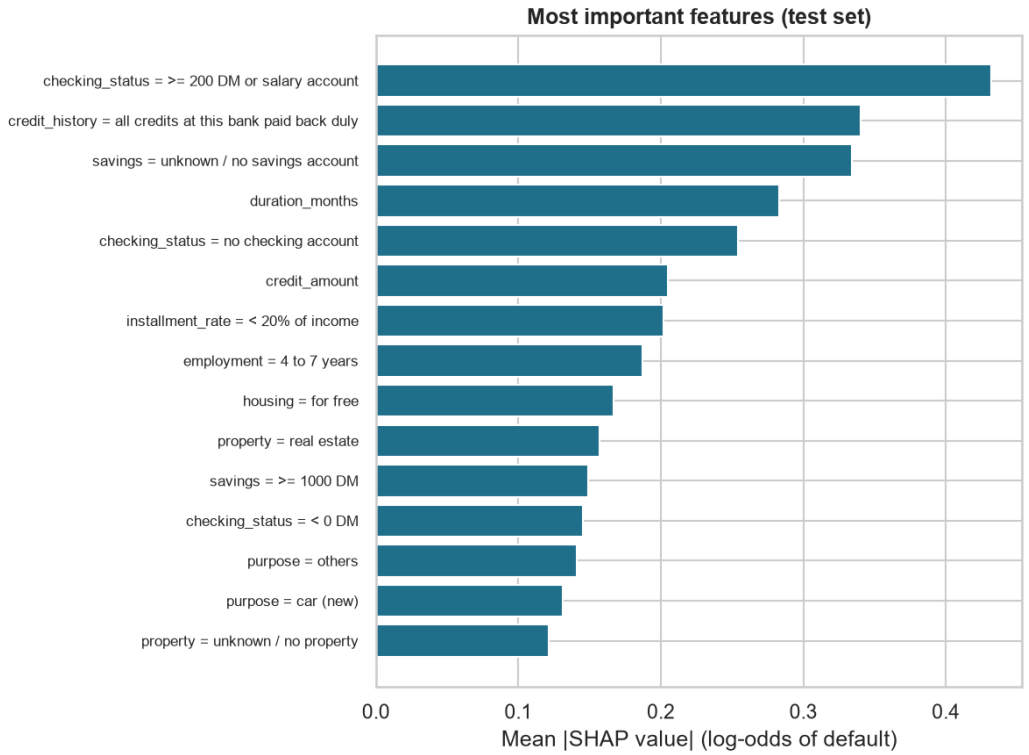


FIGURE 6 – Importance globale des variables

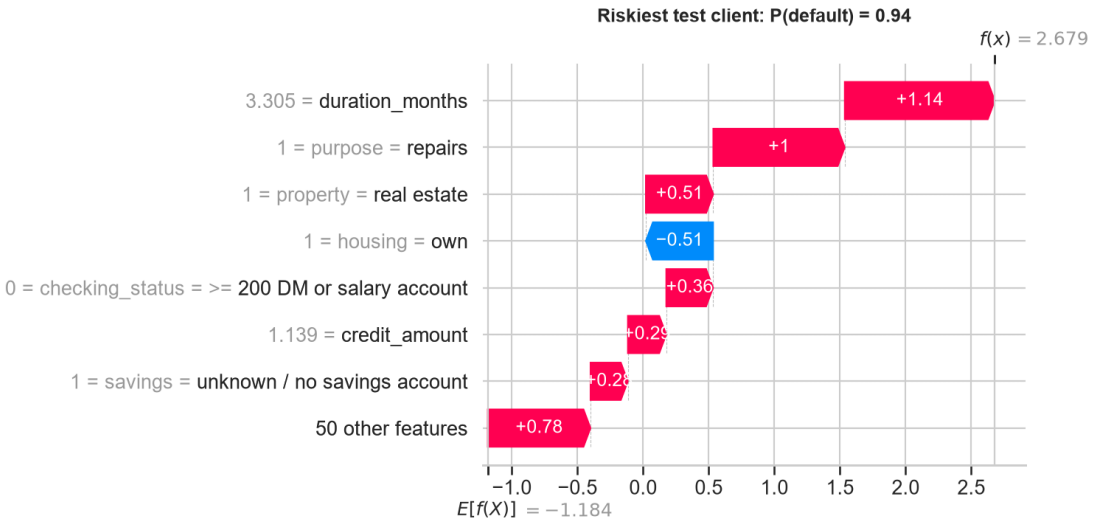


FIGURE 7 – Explication pour le client le plus risqué du test

d'un bien immobilier augmente légèrement le risque). Comme en section 5.2, ils reflètent probablement les choix passés de la banque et ne doivent pas être sur-interprétés.

5.7 Audit d'équité (Q4)

Modèle	Groupe (n)	Acceptation : groupe vs référence	DI [IC 95 %]	Écart EO [IC 95 %]
aveugle	âge ≤ 25 (190)	27,9 % vs 42,8 %	**0,65** [0,50 ; 0,81]	−12 pts [−22 ; −2]
aveugle	travailleur étranger (37)	43,2 % vs 39,9 %	1,08 [0,71 ; 1,50]	−3 pts [−20 ; +15]
complet	âge ≤ 25 (190)	24,7 % vs 44,8 %	0,55 [0,42 ; 0,70]	−18 pts [−28 ; −8]
complet	travailleur étranger (37)	73,0 % vs 39,8 %	1,84 [1,43 ; 2,21]	+24 pts [+8 ; +38]

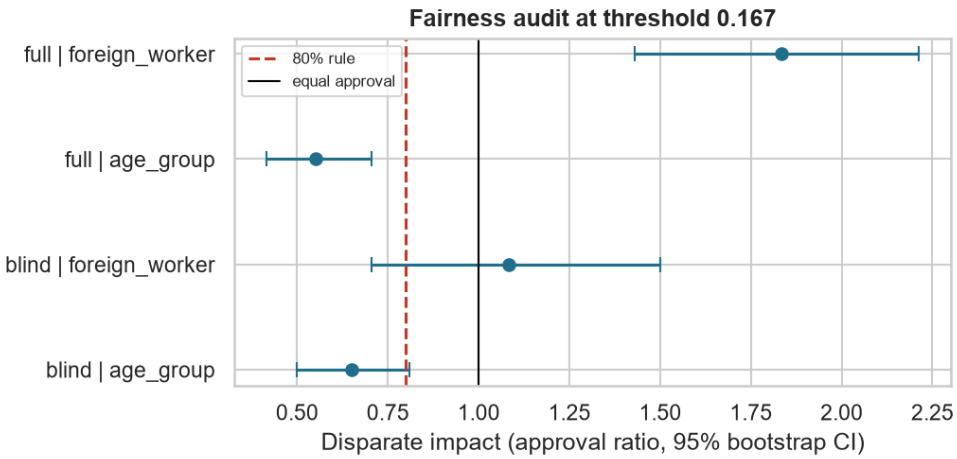


FIGURE 8 – Impact disparate avec IC à 95 %

Âge. Le modèle aveugle n'utilise pas l'âge, mais les jeunes sont beaucoup moins acceptés (DI = 0,65, sous la règle des 80 %). Même parmi les *bons payeurs*, les jeunes sont acceptés 12 points moins souvent. Une partie de l'écart vient des données : les jeunes font plus souvent défaut dans cet échantillon (42 % contre 27 %). Mais d'autres variables liées à l'âge (emploi récent, pas d'épargne, location) transmettent cette information au modèle. **Retirer la variable sensible réduit l'écart (DI de 0,55 à 0,65), mais ne le supprime pas.** On parle de discrimination par variables proxy (Pope & Sydnor, 2011 ; Barocas et al., 2023).

Travailleurs étrangers. Avec seulement 37 personnes, l'intervalle de confiance du modèle aveugle est très large (0,71 à 1,50). Nous ne pouvons pas conclure. Dans le modèle complet, les travailleurs étrangers sont acceptés *plus* souvent, car dans cet échantillon ils font moins souvent défaut (11 % contre 31 %). Ajouter une variable sensible peut donc changer les résultats dans un sens comme dans l'autre.

Sexe. Non audité, car le sexe ne peut pas être retrouvé dans les données (section 3.2). Plusieurs études passées ont utilisé une colonne « sexe » construite à partir de la table des codes fausse ; leurs conclusions sur le sexe doivent être lues avec prudence.

Coût en précision du retrait des données sensibles. Le modèle aveugle a une ROC-AUC (VC) de 0,775, le modèle complet de 0,778. Retirer l'âge et le statut de travailleur étranger ne coûte presque rien en précision. Kozodoi et al. (2022) montrent aussi que l'équité peut souvent être améliorée pour un faible coût en profit.

6. Discussion : comment évaluer plus équitablement les clients mal desservis ?

À partir de nos résultats et de la littérature, nous proposons cinq règles pratiques :

1. **Utiliser d'abord des modèles transparents.** Une régression logistique atteint une ROC-AUC de 0,80 et chaque décision peut être expliquée au client.
2. **Ne pas utiliser les données sensibles dans le modèle, mais les utiliser pour l'audit.** Retirer l'âge n'a pas supprimé l'écart lié à l'âge. Sans mesure, la banque ne verrait pas le problème (Barocas et al., 2023).
3. **Choisir le seuil volontairement.** Le seuil décide combien de bons clients perdent l'accès au crédit. Il doit utiliser le vrai taux de défaut et les vrais coûts de la banque, être écrit et révisé régulièrement.
4. **Adapter les conditions plutôt que refuser.** Les classes de risque permettent un montant plus faible, une durée plus courte ou un garant pour les clients plus risqués.
5. **Se souvenir du biais de sélection.** Le modèle n'a appris que des clients acceptés dans le passé. Les groupes souvent refusés autrefois sont sous-représentés. Des méthodes comme la *reject inference* existent, mais leur gain est souvent faible (Banasik & Crook, 2007) : la meilleure solution est de collecter de meilleures données (par exemple, en acceptant un petit échantillon aléatoire de dossiers limites).

7. Limites

— **Corrélation n'est pas solvabilité.** Le modèle trouve des régularités dans des données passées. Il ne montre pas qu'une caractéristique *cause* le défaut, et il ne doit pas servir à juger une personne.
— **Biais de sélection** (seulement des clients acceptés) et **sur-représentation** (30 % de mauvais crédits au lieu de 5 %).
— **Données anciennes, petites et locales :** 1 000 crédits du sud de l'Allemagne, 1973 à 1975. Les montants ont aussi été transformés par une fonction inconnue (Grömping, 2019).
— **Petits groupes :** 37 travailleurs étrangers ; les résultats d'équité pour ce groupe ne sont pas fiables.
— **Matrice des coûts simple :** le ratio 5 :1 est une convention fournie avec les données, pas des données réelles de banque.
— **Pas de correction d'équité :** nous avons mesuré les écarts sans tester de méthode pour les réduire. Ce serait une bonne suite au projet (Kozodoi et al., 2022).

8. Conclusion

Sur un jeu de données public, et après correction de sa table des codes, une simple régression logistique sépare bien le risque (ROC-AUC de 0,80 sur le test ; taux de défaut de 6,5 % à 62,5 % selon la classe de risque). Le seuil de décision basé sur la matrice des coûts (0,167) économise 22 % par rapport à la meilleure règle simple, mais il refuse la moitié des bons clients. Cela montre le vrai arbitrage entre risque et inclusion. L'audit d'équité montre que retirer les données sensibles ne suffit pas : les jeunes restent beaucoup moins acceptés. Les corrélations historiques peuvent aider à organiser les décisions de crédit, mais elles sont un point de départ pour le jugement humain, jamais un verdict sur une personne.

Références

Agresti, A. (2013). *Categorical Data Analysis* (3e éd.). Wiley. *(Étape 2 : test du khi-deux, V de Cramér, odds ratios.)*

Banasik, J., & Crook, J. (2007). Reject inference, augmentation, and sample selection. *European Journal of Operational Research, 183*(3), 1582–1594. https ://doi.org/10.1016/j.ejor.2006.06.072 *(Biais de sélection, reject inference.)*

Barocas, S., Hardt, M., & Narayanan, A. (2023). *Fairness and Machine Learning : Limitations and Opportunities*. MIT Press. https ://fairmlbook.org *(Pourquoi retirer les variables sensibles ne suffit pas.)*

Bland, J. M., & Altman, D. G. (1995). Multiple significance tests : the Bonferroni method. *BMJ, 310*(6973), 170. https ://doi.org/10.1136/bmj.310.6973.170 *(Étape 2 : correction de Bonferroni.)*

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review, 78*(1), 1–3. *(Étape 3 : score de Brier.)*

Demirgüç-Kunt, A., Klapper, L., Singer, D., & Ansar, S. (2022). *The Global Findex Database 2021 : Financial Inclusion, Digital Payments, and Resilience in the Age of COVID-19*. Banque mondiale. https ://doi.org/10.1596/978-1-4648-1897-4 *(Contexte : inclusion financière.)*

Efron, B., & Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. *(Étape 5 : intervalles de confiance bootstrap.)*

Elkan, C. (2001). The foundations of cost-sensitive learning. In *Proceedings of the 17th International Joint Conference on Artificial Intelligence (IJCAI)* (pp. 973–978). *(Étape 3 : seuil = C_FP / (C_FP + C_FN) ; effet de la repondération sur les probabilités.)*

Equal Employment Opportunity Commission [EEOC]. (1978). Uniform Guidelines on Employee Selection Procedures, 29 C.F.R. § 1607.4(D). *(Étape 5 : la règle des 80 %.)*

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters, 27*(8), 861–874. https ://doi.org/10.1016/j.patrec.2005.10.0 *(Étape 3 : ROC-AUC.)*

Feldman, M., Friedler, S. A., Moeller, J., Scheidegger, C., & Venkatasubramanian, S. (2015). Certifying and removing disparate impact. In *Proceedings of the 21st ACM SIGKDD Conference* (pp. 259–268). https ://doi.org/10.1145/2783258.2783311 *(Étape 5 : impact disparate.)*

Grömping, U. (2019). *South German Credit Data : Correcting a Widely Used Data Set* (Report 4/2019). Reports in Mathematics, Physics and Chemistry, Beuth University of Applied Sciences Berlin. *(Données : table des codes corrigée, 1973–1975, 5 % de défaut réel, sexe non récupérable.)*

Hand, D. J., & Henley, W. E. (1997). Statistical classification methods in consumer credit scoring : a review. *Journal of the Royal Statistical Society : Series A, 160*(3), 523–541. *(Étape 3 : régression logistique en notation de crédit.)*

Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. In *Advances in Neural Information Processing Systems 29* (pp. 3315–3323). *(Étape 5 : égalité des chances.)*

He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering, 21*(9), 1263–1284. https ://doi.org/10.1109/TKDE.2008.239 *(Étape 3 : déséquilibre des classes.)*

Hofmann, H. (1994). *Statlog (German Credit Data)* [Jeu de données]. UCI Machine Learning Repository. https ://doi.org/10.24432/C5NC77 *(Source des données.)*

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3e éd.). Wiley. *(Étape 2 : régression logistique et odds ratios.)*

Kamiran, F., & Calders, T. (2009). Classifying without discriminating. In *2nd International Conference on Computer, Control and Communication (IC4)* (pp. 1–6). IEEE. *(Étape 5 : âge ≤ 25 ans comme groupe protégé dans ce jeu de données.)*

Kerby, D. S. (2014). The simple difference formula : An approach to teaching nonparametric correlation. *Comprehensive Psychology, 3*, Article 1. https ://doi.org/10.2466/11.IT.3.1 *(Étape 2 : corrélation bisériale de rang.)*

King, G., & Zeng, L. (2001). Logistic regression in rare events data. *Political Analysis, 9*(2), 137–163. *(Étape 3 : correction des probabilités quand une classe a été sur-représentée.)*

Kozodoi, N., Jacob, J., & Lessmann, S. (2022). Fairness in credit scoring : Assessment, implementation and profit implications. *European Journal of Operational Research, 297*(3), 1083–1094. https ://doi.org/10.1016/j.ejor.2021.06.023 *(Étape 5 et discussion : équité et profit en notation de crédit.)*

Lessmann, S., Baesens, B., Seow, H.-V., & Thomas, L. C. (2015). Benchmarking state-of-the-art classification algorithms for credit scoring : An update of research. *European Journal of Operational Research, 247*(1), 124–136. https ://doi.org/10.1016/j.ejor.2015.05.030 *(Étape 3 : la régression logistique comme référence solide.)*

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30* (pp. 4765–4774). *(Étape 4 : SHAP.)*

Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics, 18*(1), 50–60. *(Étape 2 : test de Mann-Whitney U.)*

Molnar, C. (2022). *Interpretable Machine Learning : A Guide for Making Black Box Models Explainable* (2e éd.). https ://christophm.github.io/interpretable-ml-book/ *(Étape 4 : valeur SHAP d'un modèle linéaire = coefficient × (valeur − moyenne).)*

Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning* (pp. 625–632). *(Étape 3 : calibrage.)*

Pope, D. G., & Sydnor, J. R. (2011). Implementing anti-discrimination policies in statistical profiling models. *American Economic Journal : Economic Policy, 3*(3), 206–231. https ://doi.org/10.1257/pol.3.3.206 *(Étape 5 : effets proxy quand une variable sensible est retirée.)*

Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence, 1*(5), 206–215. https ://doi.org/10.1038/s42256-019-0048-x *(Étape 3 : choix d'un modèle interprétable.)*

Saerens, M., Latinne, P., & Decaestecker, C. (2002). Adjusting the outputs of a classifier to new a priori probabilities : A simple procedure. *Neural Computation, 14*(1), 21–41. https ://doi.org/10.1162/089976602753284446 *(Étape 3 : correction des probabilités de 30 % à 5 %.)*

Siddiqi, N. (2017). *Intelligent Credit Scoring : Building and Implementing Better Credit Risk Scorecards* (2e éd.). Wiley. *(Étapes 3 et 5.5 : grilles de score, classes de risque.)*

Thomas, L. C., Crook, J., & Edelman, D. (2017). *Credit Scoring and Its Applications* (2e éd.). SIAM. *(Contexte : notation de crédit, défaut, biais de sélection.)*

Union européenne. (2024). Règlement (UE) 2024/1689 établissant des règles harmonisées concernant l'intelligence artificielle (règlement sur l'IA), annexe III. *Journal officiel de l'Union européenne*. *(Contexte : la notation de crédit est un usage de l'IA à haut risque.)*

Verbraken, T., Bravo, C., Weber, R., & Baesens, B. (2014). Development and application of consumer credit scoring models using profit-based classification measures. *European Journal of Operational Research, 238*(2), 505–513. *(Section 5.4 : évaluation basée sur le profit.)*

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association, 22*(158), 209–212. *(Étape 3 : intervalle de confiance de Wilson.)*

Logiciels : Python 3.12, pandas, NumPy, SciPy, statsmodels, scikit-learn, SHAP, matplotlib, seaborn, SQLite.